기계학습 중간고사

2020020490


고려대학교 기계공학과 석사과정 문용환

moonyh1230@kist.re.kr

1. 붓꽃 데이터를 이용한 logistic regression

sklearn data 패키지의 iris_data를 활용하여 붓꽃을 분류하였다. 붓꽃 데이터는 setosa, versicolor, virginica의 세 가지 붓꽃 종(species)으로 구성된 target data와 꽃받침 길이와 폭, 꽃잎 길이와 폭의 4가지로 구성된 feature data로 이루어져 있다. 이 4종류의 feature data를 logistic regression을 통해 분류하고, 결과로 setosa와 그 이외의 종으로 구분하였다.

- Feature data와 target data의 scatter plot 및 logistic regression plot



- Logistic regression(L2 constraint application)

150개의 data set 중 임의로 선택된 112개의 training data로 나머지 38개의 target을 예측해본 결과는 다음과 같다.

	precision	recall	f1-score	support
0	1.00	1.00	1.00	13
1	1.00	1.00	1.00	25
accuracy			1.00	38
macro avg	1.00	1.00	1.00	38
weighted avg	1.00	1.00	1.00	38

2. 당뇨병 진행도 데이터를 이용한 OLS regression

sklearn data 패키지의 diabetes_data를 활용하여 OLS 회귀분석을 진행하였다. 당뇨병 진행도 데이터는 당뇨병의 진행도를 정수로 나타낸 target data와 나이, 성별, BMI 지수, 평균혈압, 그리고 6종류의 혈액검사 정보로 구성된 feature data로 이루어져 있다. 주어진 feature data를 OLS 회귀분석을 통해 분석하고, 회귀곡선을 나타내는 공식을 도출하였다.

- OLS regression(result summary)

OLS Regression Results

			=====				
Dep. Varial	ole:		DP	R-squ			0.518
Model:			0LS		R-squared:		0.507
Method:		Least Sq			tistic: /5 -+-+:-+:	- > .	46.27
Date:		Thu, 17 Jun			(F-statisti	c):	3.83e-62
Time: No. Observa	ations:	09.	30:01 442	AIC:	ikelihood:		-2386.0 4794.
Df Residua			442	BIC:			4794. 4839.
Df Model:	15.		10	DIC.			4005.
Covariance	Tyne:	nonr	obust				
========		.=====	======				
	coet	std err		t	P> t	[0.025	0.975]
const	152.1335	2.576	E		0.000	147.071	 157.196
age	-10.0122			0.168	0.867	-127.448	107.424
sex	-239.8191			3.917	0.000	-360.151	-119.488
bmi	519.8398			7.813	0.000	389.069	650.610
bp	324.3904			4.958	0.000	195.805	452.976
s1	-792.1842			1.901	0.058	-1611.169	26.801
s2	476.7458			1.406	0.160	-189.621	1143.113
s3	101.0446			0.475	0.635	-316.685	518.774
s <u>4</u>	177.0642			1.097	0.273	-140.313	494.442
s5	751 . 2793			4.370	0.000	413.409	1089.150
s6	67.6254	65.984		1.025	0.306	-62.065	197.316
Omnibus:			 1.506	Durbi	 n-Watson:		2.029
Prob(Omnibus):			0.471 Jarque-Bera (JB):			:	1.404
Skew:	30)		0.017	Prob(0.496
Kurtosis:			2.726	Cond.			227.
Nul (0313)							

- Regression equation

DP(Disease Progression) = 152.134 - 10.012 * age - 239.819 * sex + 519.840 * bmi + 324.390 * bp - 792.184 * s1 + 476.746 * s2 + <math>101.045 * s3 + 177.064 * s4 + 751.279 * s5 + 67.625 * s6

- Regression prediction and error

patient no.	DP predict	DP real	error
0	206.117070	151.0	0.365
1	68.072348	75.0	0.092
2	176.884060	141.0	0.254
3	166.917966	206.0	0.190
4	128.459842	135.0	0.048

3. 중고차 데이터를 이용한 Ridge regression

kaggle.com의 100,000 UK Used Car Data set 중 bmw 사의 중고차 데이터를 활용하여 lasso 회귀분석을 진행하였다. 중고차 데이터는 차 가격, 연식, 모델명, 급유 타입 등 9개의 feature data로 이루어져 있다. 주어진 feature data를 lasso 모형으로 분석해보았다.

- Ridge coefficient

```
[ 4274.03396413 -2836.85882873 -657.84291184 -3747.86954999
  2019.80422065 -1739.66443689 -1457.52331014 -793.5496383
  -563.97074491
                  37.23187096
                                  70.36165581
                                               884.00876313
  1664.5755971
                  360.49802416
                                 608.00006044 1257.79064917
  1252.59711754
                  214.94396995
                               -563.82913075
                                              -142.2577761
                 648.04244403 2393.20873209 1424.9870521
  787.1896652
  2546.84740961
                 517.16765466
                                103.33553591
                                              2846.79179372
  1397.88915576 -100.4994292
                                -277.46758126
                                                333.77352255
  -136.45750735
                 129.29666283 1465.14717823
                                                405.72753599
  -434.6272607 ]
```

- R square 모형 평가값
- 0.8582480408503247
- MSE 모형 평가값
- 4189.327685966202

```
4. python code
① logistic regression
from sklearn import datasets
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.linear model import LogisticRegression
from sklearn.model selection import cross val score
from sklearn.metrics import precision_score
from sklearn.metrics import confusion matrix
from sklearn.metrics import classification_report
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
# 데이터 불러오기
raw_iris = datasets.load_iris()
# 피쳐, 타겟 데이터 지정
X = raw iris.data
y = raw_iris.target
# target label 값을 0과 0 이외로 치환
y = np.where(y >= 1, 1, y)
print(y)
print(X.shape)
print(pd.DataFrame(X).head())
# 트레이닝/테스트 데이터 분할
X_tn, X_te, y_tn, y_te=train_test_split(X,y,random_state=1)
# 데이터 표준화
std_scale = StandardScaler()
std_scale.fit(X_tn)
```

```
X tn std = std scale.transform(X tn)
X_te_std = std_scale.transform(X_te)
print(X_tn_std.shape) # 데이터 크기 확인
print(y_tn.shape)
print(pd.DataFrame(y tn).head()) # y 레이블 확인
feature_id = 3 # index of feature
patient num = 50 # first number of iris
plt.figure(1, [10, 5])
plt.subplot(121)
plt.plot(np.linspace(0, 4, 5), X_tn_std[0:5, feature_id], marker = "x")
plt.title('Feature plot', fontsize = 20)
plt.subplot(122)
plt.scatter(X_tn_std[0:patient_num, feature_id], y_tn[0:patient_num])
plt.title('First ' + str(patient_num) + ' iris for ' + str(feature_id) +
'-th feature', fontsize = 20)
plt.show()
x = X_tn_std[0:patient_num, feature_id]
y = y_tn[0:patient_num]
print(y)
float_epsilon = np.finfo(float).eps
Y = np.log(y/(1 - y + float_epsilon) + float_epsilon)
print(Y)
A = [[np.sum(x * x), np.sum(x)], [np.sum(x), len(x)]]
b = [np.sum(Y * x), np.sum(Y)]
U = np.linalg.solve(A, b)
print(U)
W = U[0]
```

```
b = U[1]
plt.figure(2, [10, 5])
plt.subplot(121)
plt.scatter(x, y)
plt.subplot(121)
x_{-} = np.linspace(-2, 2, 20)
plt.plot(x_, 1 / (1 + np.exp(-W * x_ - b)), 'r') # logistic app. sol.
plt.title('Original plot for iris data')
plt.subplot(122)
plt.scatter(x, 1 / (1 + np.exp(-W * x - b)))
plt.subplot(122)
x_{-} = np.linspace(-2, 2, 20)
plt.plot(x_, 1 / (1 + np.exp(-W * x_ - b)), 'r') # logistic app. sol.
plt.title('Logistic plot for iris data')
plt.show()
clf_logi_l2 = LogisticRegression(penalty='12')
clf_logi_l2.fit(X_tn_std, y_tn)
pred logistic = clf logi 12.predict(X te std)
pred_proba = clf_logi_l2.predict_proba(X_te_std)
precision = precision_score(y_te, pred_logistic)
conf_matrix = confusion_matrix(y_te, pred_logistic)
class_report = classification_report(y_te, pred_logistic)
② OLS regression
from sklearn import datasets
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import statsmodels.api as sm
```

```
raw diabetes = datasets.load diabetes()
dfX0 = pd.DataFrame(raw diabetes.data, columns = raw diabetes.feature nam
es)
dfX = sm.add_constant(dfX0)
dfy = pd.DataFrame(raw diabetes.target, columns=["DP"])
df = pd.concat([dfX, dfy], axis = 1)
df.tail()
model = sm.OLS(dfy, dfX)
result = model.fit()
print(result.summary())
result.predict(dfX.head())
print(df.head())
3 OLS regression
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import statsmodels.api as sm
from sklearn.model selection import train test split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import Ridge
from sklearn.metrics import r2_score
from sklearn.metrics import mean_squared_error
raw_cars = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/bmw.csv')
df = pd.get_dummies(data = raw_cars, columns = ["model", "transmission",
"fuelType"])
X = df.drop("price", axis = 1)
y = df["price"]
```

```
X_tn, X_te, y_tn, y_te = train_test_split(X, y, random_state = 1)

std_scale = StandardScaler()

std_scale.fit(X_tn)

X_tn_std = std_scale.transform(X_tn)

X_te_std = std_scale.transform(X_te)

clf_Ridge = Ridge(alpha = 0.01)

clf_Ridge.fit(X_tn_std, y_tn)

print(clf_Ridge.coef_)

print(clf_Ridge.intercept_)

pred_Ridge = clf_Ridge.predict(X_te_std)

print(r2_score(y_te, pred_Ridge))

print(np.sqrt(mean_squared_error(y_te, pred_Ridge)))
```